

Отчёт по лабораторной работе №2

Разведочный анализ данных (EDA) корпуса RUSLAN

РАЗДЕЛ 1. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ

1. Цель работы

Провести разведочный анализ данных корпуса RUSLAN (RUSSian Language Audio corpus) с фонетической разметкой в формате TextGrid (с помощью библиотеки Praat).

2. Исходные данные

Корпус: RUSLAN (RUSSian Language Audio corpus).

Структура каждого TextGrid:

- tier words — пословная разметка с таймингами
- tier phones — фонемная разметка в IPA

3. Методология

3.1. Сбор данных

Из каждого TextGrid извлекались:

- слова — метка, начало, конец, длительность
- фонемы — метка, начало, конец, длительность
- паузы — пустые метки на уровне words

Результат сбора:

Сущность	Количество
Слов	317 878
Фонем	1 488 456
Пауз	62 431

3.2. Очистка данных

Удалены аномалии по порогам:

- слова > 2 сек — это уже фраза, а не слово
- фонемы > 1 сек — фонема не может длиться секунду
- паузы > 5 сек — посчитала их ошибками разметки
- пустые метки, [bracketed], NaN

Результат очистки:

Сущность	Было	Стало	Удалено
Слова	317 878	255 106	62 772
Фонемы	1 488 456	1 425 732	62 724
Паузы	62 431	62 427	4

~99% — это [bracketed] и NaN, которые всё равно надо удалить.

~1% — реальные слова с завышенной длительностью (ошибки разметки).

Удалено по причинам:

- [bracketed]: 77
- NaN: 14 962
- Пустые: 0
- duration > 2: 32

Реальных слов удалено (> 2 сек): 19 — среди них, например, «никакими» (2.05 с), «американский» (3.12 с), «книги» (3.92 с), «послереволюционной» (4.14 с) и др. Все случаи проверены вручную и признаны корректными длинными словами с завышенной длительностью произнесения.

3.3. Согласование с ЛР1

Данные ЛР2 сопоставлены с нормализованным metadata из ЛР1 (metadata_RUSLAN_22200_normalized.csv):

- Фильтр по allowed_files — оставлены только 21 279 файлов, прошедших фильтр ЛР1
- Сверка слов — сравнение слов из TextGrid с нормализованным текстом metadata
- Удаление несовпадающих — 111 файлов исключены

Итог согласования:

Метрика	Значение
Файлов после фильтра ЛР1	21 279
Совпало	21 168 (99.5%)
Не совпало по тексту	111 (0.5%)
Финальный датасет	21 168 файлов

4. Результаты анализа

4.1. Статистика по словам

Метрика	Значение
Всего слов	255 106
Средняя длительность	0.357 сек
Медианная длительность	0.350 сек
Минимум	0.010 сек
Максимум	15.115 сек
Стандартное отклонение	0.241 сек

Выводы:

- Средняя $\approx$ медиана $\rightarrow$ распределение почти симметричное
- Средняя длительность 357 мс — типично для слитной русской речи
- Максимум 15.115 сек — аномалия (неразмеченный участок, техническая ошибка?)
- Минимум 10 мс — артефакт разметки (обрывок, щелчок?)

4.2. Статистика по фонемам

Метрика	Значение
Всего фонем	1 425 732
Средняя длительность	0.073 сек
Медианная длительность	0.070 сек
Минимум	0.005 сек
Максимум	0.997 сек

Соотношение: $1\,425\,732 / 255\,106 \approx 5.59$ фонем на слово.

Топ-10 частотных фонем:

Фонема	Кол-во	Тип
ɪ	115 401	гласная
ə	108 045	гласная
e	74 937	гласная
a	63 780	гласная
t	62 173	согласная
j	55 664	согласная
ɲ	51 120	согласная
e	49 893	гласная
г	45 767	согласная
ʂ	45 418	согласная

4.3. Гласные и согласные

Класс	Кол-во	Средняя длительность
Гласные	604 154	0.056 сек
Согласные	821 578	0.086 сек

Доля гласных: $604\,154 / 1\,425\,732 \approx 42.4\%$.

Выводы:

- Согласных больше гласных (58% vs 42%) — норма для русского языка
- Согласные длиннее гласных в среднем (0.086 vs 0.056 сек) — не похоже на норму. Возможная причина: в корпусе много долгих согласных (аффрикаты, щелевые) или особенности разметки

4.4. Статистика по паузам

Метрика	Значение
Всего пауз	62 427
Средняя длительность	0.139 сек
Медианная длительность	0.070 сек
Минимум	0.025 сек
Максимум	4.876 сек

Процентили:

Перцентиль	Значение
10%	0.030 сек
25%	0.030 сек
50%	0.070 сек
75%	0.190 сек
90%	0.360 сек
95%	0.460 сек
99%	0.620 сек

Выводы:

- 90-й перцентиль 360 мс — реальные паузы
- Максимум 4.876 сек — длинная смысловая пауза




Рис. 1. Гистограммы распределений длительностей слов, фоном, гласных, согласных и пауз

4.5. Классификация пауз по длительности

Класс	Кол-во	Доля
Сверхкороткая (< 50 мс)	26 882	43.1%
Короткая (50–100 мс)	9 338	15.0%
Средняя (100–200 мс)	10 961	17.6%
Длинная (200–500 мс)	12 972	20.8%
Очень длинная (500–1000 мс)	2 204	3.5%
Сверхдлинная (> 1 сек)	70	0.1%

Выводы:

- 58% пауз короче 100 мс — очень короткие паузы
- 24% пауз длиннее 200 мс — реальные межсловные паузы
- 3.6% пауз длиннее 500 мс — долгие смысловые паузы




Рис. 2. Классы пауз по длительности

4.6. Позиция пауз в файле

Позиция	Кол-во	Доля	Средняя длит.
В середине	49 028	78.6%	0.163 сек
В конце	12 391	19.9%	0.049 сек
В начале	996	1.6%	0.057 сек

Кросс-таблица (позиция × класс):

Позиция	< 50 мс	50–100	100–200	200–500	500–1000	> 1 сек
В конце	10 836	744	571	162	42	36
В начале	796	60	93	43	4	0
В середине	15 249	8 534	10 293	12 767	2 158	27




Рис. 3. Распределение классов пауз по позиции в файле

Выводы:

- Паузы в конце/начале — артефакты разметки (80–87% < 50 мс)
- Паузы в середине — реальные (30% > 200 мс)
- Парадокс: паузы в конце короче, чем в середине, возможно, это технические зазоры?

4.7. Анализ контекста длинных пауз

Для пауз > 0.5 сек (2 002 шт.) извлечены фразы ±5 слов. Примеры:

Фраза	Вердикт
...выговорил он [0.92] но я бы хотел...	Пауза перед «но»
...он думал [0.55] там лежит фляга...	Хезитация
...поэтами Рейном [0.77] Найманом Бродским...	Перечисление
...в фойе [0.60] и невнятно объяснился...	Граница клауз
...разбиваются [0.50] кричал Веселов...	Прямая речь
...говорит [0.59] вот суки...	Перед вводным
...фольклор [0.75] эстетические каноны...	Смысловая граница
...опротивела [0.58] но тогда я был полон...	Перед «но»

Вывод: все паузы > 0.5 сек логичны. Они озвучивают:

- знаки препинания (запятые, тире, точки)
- синтаксические границы (перед «но», «а»)
- хезитации (после глаголов речи/мысли)
- перечисления

5. Согласование с ЛР1

5.1. Проблема несовпадений

При сверке TextGrid с metadata ЛР1 обнаружено 20 708 «несовпадений». Анализ показал:

Причина 1: NaN в сырых данных

В words_data.csv пустые метки сохранились как NaN и попадали в подсчёт.

Причина 2: дефисные слова

В TextGrid используется Unicode-дефис - (U+2010), в metadata — обычный пробел:

- как-то (Grid) vs как то (Meta)
- какой-то vs какой то
- татаро-монгольское vs татаро монгольское

Причина 3: разные версии текста

Для 111 файлов metadata содержит вставки/правки, которых нет в TextGrid, например: «или почти всем...» (Grid) vs «женщинам разумеется или почти всем...» (Meta).

5.2. Финальное согласование

После нормализации дефисов:

Метрика	Значение
Файлов	21 279
Совпало	21 168 (99.5%)
Не совпало	111 (0.5%)

111 несовпадающих файлов удалены — это разные версии текста, не ошибки разметки.

6. Финальный датасет

Сущность	Количество
Файлов	21 168

Сущность	Количество
Слов	~243 000
Фонем	~1 360 000
Гласных	~575 000
Согласных	~785 000
Пауз	~59 500

Характеристики:

- Разметка валидна (99.5% совпадений с metadata)
- Нормализованный текст привязан к словам
- Паузы логичны и несут просодический смысл
- Корпус пригоден для обучения TTS-модели

7. Выводы

1. Корпус RUSLAN содержит 21 168 валидных файлов с пословной и фонемной разметкой.

2. Разметка качественная:

- 5.59 фонем на слово — реалистично
- 42% гласных, 58% согласных — норма для русского
- Паузы несут просодический смысл

3. Проблемы разметки:

- Аномалии (слова до 15 сек, фонемы до 1 сек)
- Микро-паузы (< 50 мс) — 43% всех пауз
- Артефакты в начале/конце файлов (80–87% < 50 мс)

4. Согласование с ЛР1:

- 99.5% файлов совпали с нормализованным metadata
- 111 файлов исключены (разные версии текста)
- Проблема дефисов решена нормализацией

5. Корпус пригоден для TTS:

- Паузы систематичны, их можно моделировать
- Нормализованный текст готов к использованию
- Тайминги слов и фонем валидны

8. Артефакты

Файл	Содержимое
words_final.csv	Слова + тайминги + нормализованный текст
phones_final.csv	Фонемы + тайминги
vowels_final.csv	Гласные
consonants_final.csv	Согласные
pauses_final.csv	Паузы
duration_distributions.png	Гистограммы распределений

Файл	Содержимое
pause_classes.png	Классы пауз
pause_position_classes.png	Позиция × класс пауз

9. Финальные данные

Показатель	Значение
Файлов	21 168
Слов	243 981
Фонем	1 367 414
Гласных	579 539
Согласных	787 875
Пауз	58 752

Финальные данные сохранены в *_final.csv

Раздел 2. Эксперименты

1. Цель работы

Разработать класс `PausePredictor`, который для последовательности токенов предсказывает:

- наличие паузы после каждого токена (`is_pause_after`)
- длительность паузы (`pause_duration`)

Целевые метрики:

$F1 \geq 0.80$ для `is_pause_after` на test

$MAE \leq 0.10$ сек для `pause_duration` на True Positive

2. Исходные данные

Корпус: RUSLAN

Формат разметки: TextGrid (Praat)

Данные: `RUSLAN_pause_metadata.csv` (245 939 токенов, 21 168 файлов)

Train/Test split: `id % 5 == 0` → test, иначе train (80/20)

Распределение классов:

- Без паузы: 79.2%
- С паузой: 20.8%

3. Реализованные подходы

3.1 Dummy-классификаторы

Модель	Test F1	Test MAE
Dummy (most_frequent = 0)	0.000	N/A
Dummy (constant = 1)	0.343	0.121

Анализ:

Dummy-модели задают нижнюю границу качества.

`most_frequent = 0` → $F1 = 0$, потому что модель никогда не предсказывает паузу.

`constant = 1` → $F1 = 0.34$, потому что модель всегда предсказывает паузу ($Precision = \text{доля пауз в данных} = 20.8\%$).

3.2 Бейзлайн на пунктуации

Идея: пауза ставится после слова, если в `label_raw` есть знак препинания (, - . ? ! ...).

Длительность — средняя по типу знака, посчитанная на train:

Знак	Средняя длительность (сек)
,	0.154

-	0.189
.	0.213
?	0.208
!	0.201
...	0.198
"	0.190

Результат:

Метрика	Train	Test
Precision	0.729	0.718
Recall	0.708	0.707
F1	0.719	0.713
MAE	0.125	0.124

Бейзлайн не переобучается — $\text{train} \approx \text{test}$. $F1 = 0.713$ — ниже цели 0.80.
Роль: точка отсчёта для сравнения ML-моделей.

3.3 CatBoost + Navec эмбединги

Признаки (302):

300 — эмбединг Navec (hudlit_v1_12B, 500K слов, 94.3% покрытие).

Слова из корпуса RUSLAN, которых нет в Navec:

Метрика	Значение
Уникальных слов в train	41 610
Найдено в Navec	39 232 (94.3%)
Не найдено (OOV)	2 378 (5.7%)

Примеры слов, которые отсутствуют в Navec, но присутствуют в Ruslan:

жилконтора, фановую, венерологом, квартуполномоченному, отдавившему, болонке, постимп рессионизму, неорганична, федосеенко и др.

Отсутствие данных слов в Navec не показалось мне преградой к использованию данных эмбедингов.

1 — длина слова

1 — наличие пунктуации

Модель: CatBoostClassifier + CatBoostRegressor

Результат:

Метрика	Train	Test
F1	0.767	0.710
MAE	0.087	0.116

Анализ:

Эмбединги не превзошли бейзлайн по F1 (0.710 vs 0.713), но улучшили MAE (0.116 vs 0.124).

Разрыв train/test = 0.057 — умеренное переобучение.

Вывод: эмбединги полезны для длительности, но не для факта паузы.

3.4. Random Forest + Navec

Метрика	Train	Test
F1	0.768	0.611

Анализ:

Похоже, RF сильно переобучается — разрыв 0.157.

Вывод: CatBoost устойчивее RF к переобучению.

3.5. CatBoost + Navec + POS + контекст + синтаксис

Признаки (958):

Группа	Размер	Что кодирует
Navec	300	Семантика текущего слова
POS (pymorphy2)	18	Часть речи (one-hot)
Длина	1	Число символов
Пунктуация	1	Есть ли знак в конце
Контекст (± 1)	600	Эмбединги соседних слов (prev + next)
Синтаксис (Natasha)	37	Граница клаузы, сочинит. союз, глубина, расстояние, deprel

Результат:

Метрика	Train	Val	Test
F1	0.779	0.774	0.704

Анализ:

Переобучение — train 0.78 vs test 0.70.

Вывод: больше признаков $\neq$ лучше. Простой CatBoost (302) лучше.

3.6. CatBoost + Navec + POS + фильтр микро-пауз (> 0.10)

Фильтр	F1 (test)
> 0.05	0.680
> 0.10	0.596

Анализ:

Фильтр > 0.10 сломал обучение.

Вывод: фильтр > 0.05 — оптимальный. > 0.10 — слишком агрессивный.

3.7. Logistic Regression + Navec + POS

Метрика	Test
---------	------

F1	0.667
MAE	0.121

Анализ:

Линейная модель хуже CatBoost (0.667 vs 0.710).

Вывод: деревья (CatBoost) лучше линейных моделей для этой задачи.

3.8. rubert-tiny2 + Navec + Syntax

Группа	Размер	Что кодирует
rubert-tiny2	312	Контекстные эмбединги (разные для одного слова в разных контекстах)
Navec	300	Семантика текущего слова
Длина	1	Число символов
Пунктуация	1	Есть ли знак в конце
Синтаксис (Natasha)	5	is_clause_boundary, is_cc, depth, dist_left, dist_right

Всего 619

Результат:

Метрика	Train	Val	Test
F1	0.750	0.726	0.7238
MAE	0.120	—	0.1236

Анализ:

Лучший ML-результат (F1 = 0.7238). Превзошёл бейзлайн на +0.011.

Вывод: контекстные эмбединги полезны для предсказания пауз.

3.9. Ансамбль (soft voting)

Базовые модели: CatBoost + LogReg + CatBoost (alt params)

Результат:

Метрика	Test
F1	0.7206

Анализ:

Ансамбль не улучшил метрику кардинально — модели коррелированы (обучаются на Navec).

Вывод: использовать ансамбль не помогает.

3.10. CRF (Conditional Random Field)

Метрика	Train	Test
F1	0.845	0.536

Анализ:

Сильное переобучение — разрыв 0.309.

Вывод: CRF не подходит для большого корпуса (17 000 предложений).

3.11. BiLSTM + Navec

Результат:

Метрика	Train	Test
F1	0.768	0.595

Анализ:

Переобучение — разрыв 0.173.

Причина: RNN требует больше данных (миллионы примеров).

Вывод: RNN не подходит для 180k токенов.

3.12. RuBERT-base fine-tuning (3 эпохи)

Модель: DeepPavlov/rubert-base-cased (768-dim)

Метрика	Train	Test
F1	0.857	0.7229
MAE	0.110	0.1157

Анализ:

Лучший MAE среди всех ML-моделей (0.1157). F1 = 0.7229 — почти как CatBoost.

Вывод: fine-tuning перспективен, но требует GPU для большего числа эпох.

4. Сводная таблица результатов

№	Модель	Test F1	Test MAE
1	Dummy (most_frequent)	0.000	N/A
2	Dummy (constant=1)	0.343	0.121
3	Бейзлайн (пунктуация)	0.713	0.124
4	CatBoost + Navec (302)	0.710	0.116
5	RandomForest + Navec	0.611	0.118
6	CatBoost + Navec + POS	0.680	0.119
7	CatBoost + Navec + POS + context + syntax (958)	0.704	0.114
8	CatBoost + rubert-tiny2	0.692	0.126
9	LogisticRegression + Navec + POS	0.667	0.121
10	CatBoost + Navec + Syntax + Threshold	0.7218	0.11–0.12
11	CatBoost + rubert-tiny2 + Navec + Syntax + Threshold	0.7238	0.1236
12	Ансамбль (soft voting)	0.7206	?
13	CRF + Navec + Syntax	0.536	0.116
14	BiLSTM + Navec	0.595	0.112
15	RuBERT-base fine-tuned	0.7229	0.1157
—	Цель	0.80	0.10

5. Анализ результатов

5.1. Потолок F1

Все модели упираются в $F1 \sim 0.72$.

Возможные причины:

71% пауз обозначены пунктуацией → бейзлайн их ловит

29% пауз — микро-паузы (< 50 мс) и хезитации — не предсказуемы по признакам

Ни одна модель не преодолела 0.73

5.2. Лучший F1

CatBoost + rubert-tiny2 + Navec + Syntax + Threshold

$F1 = 0.7238$.

5.3. Лучший MAE

RuBERT-base fine-tuned

$MAE = 0.1157$ (ближе всего к цели 0.10).

6. Финальное решение

Класс PausePredictor реализован на основе:

CatBoostClassifier + CatBoostRegressor

Эмбединги Navec (hudlit_v1_12B, 300-dim)

Признаки (302): эмбединг + длина + пунктуация

Порог подобран на валидации (0.7)

Файлы:

pause_clf.pkl — классификатор

pause_reg.pkl — регрессор

word_to_emb.pkl — эмбединги

best_threshold.pkl — порог

7. Выводы

Целевых метрик достичь не удалось, хотя были реализованы 4 подхода из задания:

- Бейзлайн на пунктуации ($F1 = 0.713$)
- Эмбединги + классические ML ($F1 = 0.710$)
- Морфология + синтаксис + ML ($F1 = 0.704$)
- Sequence2Sequence (BiLSTM, $F1 = 0.595$)

Целевые метрики не достигнуты:

$F1 = 0.7238 < 0.80$ (лучший результат)

$MAE = 0.1157 > 0.10$ (лучший результат)

Лучший результат: CatBoost + rubert-tiny2 + Navec + Syntax + Threshold (**$F1 = 0.7238$**).

8. Артефакты

Файл	Содержимое
pause_predictor.py	Класс PausePredictor
train_models.py	Обучение CatBoost + Navес
pause_clf.pkl	Классификатор
pause_reg.pkl	Регрессор
word_to_emb.pkl	Эмбединги Navес
best_threshold.pkl	Оптимальный порог