1. Предобработка фонетических данных

1.1. Артефакты

Из разметки .TextGrid (корпус RUSLAN, 22 199 предложений) подготовлены четыре файла:

Файл	Назначение	Уникальных единиц
data/tokens_phones.csv	обучение G2P (без <SIL>)	21 281 предложение
data/tokens_phones_sil.csv	метаданные для акустической модели (с <SIL>)	59 411 <SIL>
data/lexicon.csv	словарь произношений по train	41 131 слово
data/russian_mfa.dict	оригинальный MFA-словарь	153 486 слов

1.2. Методика

- Сопоставление слов и фонем — по перекрытию интервалов: фонема принадлежит слову, если её центр попадает в интервал слова.
- Инвентарь фонем — 56 символов: 55 целевых + spn.
- Словарь lexicon.csv построен только по train-части. Пересечения с test словами нет.
- ---

2. Разведочный анализ фонемного инвентаря

3. OOV-анализ (OOV = нет в train (lexicon))

Метрика	Значение
OOV train к `russian_mfa.dict`	12 588 / 41 610 = 30.25%
OOV test к `russian_mfa.dict`	4 033 / 17 192 = 23.46%
OOV test к train	5 622 / 17 192 = 32.70%

Ключевой вывод: треть тестовых слов не встречается в train. Это основная сложность задачи: G2P должен уметь транскрибировать незнакомые слова. Именно для этого в архитектуре G2P предусмотрен отдельный OOV-модуль, и именно по нему задание ставит отдельный порог PER ≤ 0.20.

---

4. Корректность разметки на проблемных примерах

Из 22 199 размеченных предложений лаба 1 отбраковала 918 (4.13%).

Анализ токенов в оставшихся 21 281 предложении:

Тип	Количество	%
Типографские дефисы (что-то)	2 090	0.85%
ASCII-дефисы (-)	3	0.001%
Метка spn (вкл. [bracketed])	2 249	0.91%
… из них [bracketed]	106	0.04%

Вывод: фильтр лабы 1 работает корректно. Все проблемные примеры (аббревиатуры, числа, латиница, сокращения) удалены на предыдущем этапе. Требует внимания при подаче в модель, — нормализация дефисов.

---

5. Омографы и ударение

Анализ lexicon.csv: из 41 131 слова только 671 (1.63%) имеют 2+ произношения. Однако настоящих омографов с разным ударением среди них крайне мало:

Слово	Вхождений в train	Варианты
замок	3	ʐ̪ a m ə k (×2), ʐ̪ ɐ m o k (×1)
мука	4	m ʊ k a (×3), m u k ə (×1)
парить	1	только p ɐ rʲ i tʲ
пропасть	1	только p r o p ə sʲ tʲ
атлас	1	только a t̪ ɫ ə s̪

1. Большинство «многовариантных» слов — не омографы, а предлоги (с, в, из, к, про) имеют варианты из-за озвончения, оглушения и редукции. Омографы, скорее всего не повлияют на качество.
2. Сравнение с MFA-словарём: russian_mfa.dict содержит оба варианта для почти всех классических омографов, но порядок рангов не всегда очевидный: например, для звонок rank 0 = разговорный звОнок, rank 1 = литературный звонОк; для уже rank 0 = разговорный ужэ. Поэтому в G2P решено опираться на частоты из lexicon.csv (реальный корпус), а не на ранги MFA-словаря.
3. Влияние на PER. Из-за крайней редкости омографов в корпусе (единицы вхождений на ~197 тыс. train-токенов) ошибки на них дают вклад менее 0.01% к PER — на два порядка меньше порога 0.025. Проблема омографов в данной задаче незначительна.

---

6. Модуль транскрипции G2P

6.1. Архитектура

Реализован класс G2P в labs/lab3_g2p/g2p.py с методом transcribe(tokens) -> list[list[str]], который принимает последовательность токенов (слов, возможно с <SIL>) и возвращает последовательность фонемных списков той же длины.

1. Иерархия принятия решения (в порядке приоритета):
2. Контекстные правила для предлогов — для в, с, из, к, от, об, под, над, без - произношение выбирается по первому звуку следующего слова.
3. Основной словарь (lexicon.csv, построен по train) — берётся наиболее частое произношение слова.
4. MFA-словарь (russian_mfa.dict, rank=0) — используется как источник для слов, отсутствующих в train-словаре.
5. OOV-эвристики — для слов, отсутствующих в словарях.
6. Все ключи словарей нормализуются (типографские дефисы – в ASCII, нижний регистр), что позволяет находить слова с разными вариантами дефиса.

6.2. OOV-модуль

1. Нормализация: замена всех типографских дефисов на ASCII; нижний регистр.

2. Предобработка:

- Схлопывание двойных согласных: нн → н, сс → с.
- Замена специальных сочетаний: дж → dʒ, тч/дч → tɕ, сч/зч → ɕ, сж/зж → ʐ, вств → s̪ t̪ v, стн → s̪ n̪.

3. Эвристика ударения:

- ё всегда ударная.
- Типичные окончания (-ение, -ание, -ация, -ость, -ать, -ить, -ка, -ец, -ая, -ое и др.) — ударение на определённый слог с конца.
- Иначе — предпоследний слог.

4. Посимвольный разбор:

- Йотированные гласные (я, е, ю, ё): после согласной — a/e/u/o без j; в начале/после гласной — j a/j e/j u/j o. С учётом редукции: безударные → ɪ/ʊ/ə.
- Обычные гласные с редукцией: ударный — полный; слог перед ударным — ɐ/ɪ/ʊ; остальные — ə/ɪ/ʊ.
- После ш, ж, ц: е, и → ɨ; о — не редуцируется.
- Согласные с палатализацией: к → c, г → ɟ, л → ʎ, н → ɲ, х → ç, остальные — bʲ, vʲ, dʲ, zʲ, mʲ, pʲ, rʲ, sʲ, tʲ, fʲ.
- Оглушение: в конце слова (б → p, в → f, г → k, д → t̪, ж → s̪, з → s̪) и перед глухими.

5. Специальные окончания:

- -ться/-тся → t̪ s̪ ə,
- -ого/-его → ə v ə,
- -ее → e j e,
- -ие → ɪ j e,
- -ия → ɪ j ə.

6.3. Обработка <SIL> и spn

- <SIL> проходит через transcribe без изменений.
- spn исключается при загрузке: токены с phones = spn отбрасываются вместе с эталоном (2249 токенов, 0.91%).

6.4. Результаты

Метрика	Train	Test	Порог
Running text PER	0.0075	0.0260	≤ 0.025
In-vocabulary PER	0.0075	0.0101	—
OOV PER	nan	0.0941	≤ 0.20
OOV word accuracy	nan	0.6137	—

6.6. Вклад отдельных компонентов в порядке добавления

Компонент	OOV PER	Running text PER
Baseline (пустой OOV)	1.0000	0.1969
+ таблица графем → фонем	0.5003	—
+ палатализация	0.3896	0.0819
+ мягкие пары MFA (ɕ, ʎ, ɲ)	0.3376	0.0720
+ редукция 1-го/последнего слога	0.2635	0.0580
+ ого/его	0.2585	0.0571
+ редукция средних слогов	0.2522	0.0559
+ двойные согласные + оглушение	0.2276	0.0512
+ редукция йотированных + ш/ж/ц	0.1995	0.0459

Компонент	OOV PER	Running text PER
+ улучшение ударения + сочетания	0.1959	0.0452
+ MFA-словарь (fallback)	0.0941	0.0260

6.8. Ограничения

1. MFA-словарь не покрывает дефисные слова (`что-то`, `как-то`, `из-за`) — в нём всего 2 слова с дефисом (`м-м-м`, `э-э`).
2. Эвристика ударения ошибается в ~35% случаев — основной источник ошибок моего OOV-модуля.
3. In-vocabulary PER = 0.0101 — из-за многовариантных предлогов, скорее всего.
4. Оставшийся зазор running text PER (0.0260 vs 0.025) можно закрыть, вероятно, более точной эвристикой ударения.

---

7. Подготовка метаданных для акустической модели (лаба 4)

7.1. Формат метаданных

Подготовлены два файла в формате id|text|phones:

Файл	Источник фонем	Назначение
data/metadata_phones_gt.csv	эталонная разметка из tokens_phones_sil.csv	обучение на «чистых» данных
data/metadata_phones.csv	предсказание модуля G2P	обучение на «реалистичных» данных

Разделитель полей — |, разделитель фонем — пробел. Токен <SIL> сохранён на месте пауз. Все фонемы принадлежат целевому инвентарю common/phones_mfa.txt.

7.2. Методика подготовки

1. Из tokens_phones_sil.csv удалены токены со spn (2249 токенов, 0.91%).
2. Токены сгруппированы по id предложения и отсортированы по token_id.
3. Текст предложения собран как конкатенация токенов через пробел.
4. Фонемы собраны как конкатенация фонемных последовательностей через пробел:
   - для metadata_phones_gt.csv — эталонные фонемы,
   - для metadata_phones.csv — предсказанные модулем G2P.

   Можно будет использовать предсказанный вариант как основной — он ближе к реальным условиям работы. Эталонный — как baseline для сравнения.

---

8. Оценка объёма проблемы омографов и её влияния на метрику

8.1. Объём проблемы

В lexicon.csv: 671 слово из 41 131 (1.63%) имеют 2+ произношения. Однако настоящих омографов с разным ударением среди них крайне мало (см. раздел 5). Большинство «многовариантных» слов — предлоги, имена собственные, сложные слова.

8.2. Анализ ошибок in-vocab

Топ-10 ошибочных in-vocab слов дают ~70% всех ошибок:

Слово	Ошибок	Всего	% ошибок
в	574	1311	44%
на	191	569	34%
из	113	213	53%
все	108	234	46%
что	79	506	16%
не	49	788	6%
с	46	444	10%
то	37	141	26%

Слово	Ошибок	Всего	% ошибок
при	26	47	55%
до	16	80	20%

Вывод: in-vocab PER = 0.0101 — это преимущественно ошибки на предлогах и служебных словах с многовариантным произношением, а не на классических омографах.

8.3. Принятое решение и его обоснование

Решение: для омографов берётся самое частое произношение из train-словаря.

Обоснование:

1. Простота и надёжность — не требует контекста, работает на уровне слова.
2. Малый вклад в ошибки — омографы-предлоги дают ~15% running text PER, и даже полное их решение не снизит PER ниже 0.025 без улучшения OOV.
3. Неудачный эксперимент с контекстом — попытка применить контекстные правила для предлогов ухудшила метрику (in-vocab PER вырос с 0.0101 до 0.0120), вероятно, потому что правила не всегда совпадают с реальной статистикой корпуса.
4. MFA-словарь не решает проблему — его порядок рангов не всегда кажетсяя правильным (например, для звонок rank 0 = разговорный звОнок, rank 1 = литературный звонОк).

---

9. Итоги

9.1. Результаты по метрикам

Метрика	Значение (test)	Порог	Статус
OOV PER	0.0941	≤ 0.20	✅ достигнут
Running text PER	0.0260	≤ 0.025	⚠ на 0.001 выше
OOV word accuracy	0.6137	—	61% OOV-слов точно
In-vocabulary PER	0.0101	—	—

9.2. Итоги

1. OOV PER = 0.0941 — на порядок лучше порога 0.20.
2. Running text PER немного не дотянула= 0.0260 — на 4% выше порога 0.025 (96% от требуемого).
3. 61% OOV-слов предсказаны точно — несмотря на то, что это эвристический модуль.
4. Использование MFA-словаря как fallback решило проблему OOV-слов, которых нет в train.